



Resto Score

ETL

2do Sprint

Contexto del Proyecto:




- Análisis de reseñas de negocios en EE.UU. para determinar ubicaciones óptimas de inversión en restaurantes.
- Uso de datos de Yelp, Google Maps y fuentes macroeconómicas.
- Desarrollo de un sistema de recomendación, y un dashboard interactivo para medir el rendimiento de la cantidad y puntaje de reseñas positivas.



Objetivos del Sprint 2

- 
- 
- 
- Completar el ETL .
 - Implementar la estructura de datos.
 - Automatizar el pipeline ETL.
 - Finalizar el diseño del Modelo ER.
 - Construir los pipelines.
 - Elaborar la documentación técnica.
 - Desarrollar un Proof of Concept (PoC) del dashboard.
- 
- 



Estado actual: Tareas hasta semana 4 completadas.

Proyecto Final Grupo 3 Henry 2025 Data Science

Tareas	Semana 1	Semana 2	Semana 3	Semana 4	Semana 5	Semana 6
Metodología y Diseño	Propuesta de trabajo					
Preparar entregables	Flujo de Trabajo, Roles y división de Trabajo.					
EDA	Reporte de datos					
Objetivos y KPIs		Definir Entregables				
ETL + DL + DER		Implementar DL + Carga de Datos Crudos + Tablas y DER				
Carga incremental		Establecer Métodos de Carga en DL y Carga incremental en Query				
Dashboard			Pruebas , modelos preliminares, diseño final entregable			
Algoritmo ML			Desarrollar, Entrenar y Desplegar Algoritmo			

Roles: Documentar Analítica Ingeniería

Diccionario de Datos



- Especifica la estructura de la base de datos utilizada en el análisis.
- Define los nombres de las columnas, tipos de datos y su significado.
- Facilita la comprensión y uso de los datos para análisis y modelado.

Ejemplo de algunos campos clave:

Columna	Tipo de Dato	Descripción
<code>business_id</code>	STRING	ID único del negocio.
<code>name</code>	STRING	Nombre del negocio.
<code>stars</code>	FLOAT	Calificación promedio del negocio.
<code>review_count</code>	INT	Número de reseñas recibidas.
<code>text</code>	STRING	Contenido de la reseña.



Repositorio en GitHub con la base de datos completa:

https://github.com/JamesRaynor007/ProyectoGrupalHenry/blob/main/Sprint2/README_Sprint2.md

E T L

Análisis de Datos de Muestra



01

Metadata

Contiene el global de los locales comerciales, nos interesa para filtrar por rubro, estado y categorías. Su consistencia es muy buena.

02

Yeld

No se han encontrado datos relevantes para su utilización, el faltante de completitud en los estados hizo que fueran desestimados de utilizarse.

03


Reviews

Junto con Metadata, se cruzaron para obtener los locales comerciales objetivo y de allí se filtraron las reseñas repetidas. Serán bien analizados para alimentar los algoritmos de análisis de sentimiento y recomendaciones.






*"En todo gran equipo
aparecen grandes ideas".*



docker



WorkFlow



Se seleccionan datos para crear Dashboards y algoritmos específicos.

USE

***Aplicar actualización incremental programada.*

LOAD

Script de docker crea base de datos y carga los datos limpios

Script de docker realiza transformación y limpieza de datos crudos.


TRANSFORMATION

RAW DATA – EXTRACTION


Script de docker descarga y almacena en volumen.




Pipeline Automatizado (DOCKER)



DATAWAREHOUSE LOCAL





Estructura de Datos – DER




Versión— GOOGLE CLOUD

- Respetando nuestra sprint 1, nuestro equipo de data engineering desarrolló exitosamente la implementación en cloud.
- A continuación Richard nos mostrará como se practica la carga incremental para evitar tiempos de carga extensos y ser eficiente en el uso de recursos.
- Y se presentará un video donde Verónica nos muestra como se actualiza el almacenamiento en la nube.







The screenshot displays a Jupyter Notebook environment with a file explorer on the left showing a project structure with folders 'project1', 'project2', and 'temp', and a file 'ETL_Automatizado.py'. The main area shows the code for 'ETL_Automatizado.py'.

```

from google.cloud import storage, bigquery
import pandas as pd

# Configuración de clientes de GCS y BigQuery
storage_client = storage.Client()
bigquery_client = bigquery.Client()

# Definición de rutas de almacenamiento
bucket_name = "restaurant-data-bucket"
bucket_client = storage.Bucket(storage_client, bucket_name)

# Definición de rutas de archivos
file_path_1 = "restaurant_data/restaurant_data.csv"
file_path_2 = "restaurant_data/restaurant_data_2.csv"
file_path_3 = "restaurant_data/restaurant_data_3.csv"
file_path_metadata = "restaurant_data/metadata.csv"

# Carga de datos desde almacenamiento
def load_data_from_storage(bucket_client, file_path):
    blob = bucket_client.get_blob(file_path)
    if blob is not None:
        data = blob.download_as_string().decode('utf-8')
        df = pd.read_csv(data)
        return df
    else:
        return None

# Carga de datos desde BigQuery
def load_data_from_bigquery(query):
    query_job = bigquery_client.query(query)
    df = query_job.to_dataframe()
    return df

# Ejecución de la ETL
def main():
    # Carga de datos desde almacenamiento
    df1 = load_data_from_storage(bucket_client, file_path_1)
    df2 = load_data_from_storage(bucket_client, file_path_2)
    df3 = load_data_from_storage(bucket_client, file_path_3)

    # Carga de datos desde BigQuery
    df4 = load_data_from_bigquery("SELECT * FROM restaurant_data")

    # Combinación de datos
    df = pd.concat([df1, df2, df3, df4], ignore_index=True)

    # Guardado de datos en almacenamiento
    df.to_csv(file_path_metadata, index=False)

if __name__ == "__main__":
    main()


```


The bottom status bar shows system information: 16 GB of RAM, 16 GB of storage, and a system clock showing 11:51 AM on 10/10/2023.

ETL AUTOMATIZADO





Pipeline Automatizado






100



Proof Of Concept – Dashboard



Se solicita un Promedio Alto

Y una cantidad considerable de Valoraciones

Proof Of Concept – ML Recomendación



```
recomendar_restaurantes(ML_BASE, diccionario_categorias, 'Texas')
```

✓ 0.0s

Restaurantes Recomendados:

Recomendación #150302:

Nombre: Sam's Club Bakery

Promedio: 4.4

Valoraciones: 8

Categorías: Categoría Desconocida, Categoría Desconocida, Categoría Desconocida

Atributos: Takeout, Delivery, Asientos Discapacitados

Recomendación #163223:

Nombre: Subway

Promedio: 3.8

Valoraciones: 84

Categorías: Categoría Desconocida

Atributos: Takeout, Delivery, Asientos Discapacitados, Almuerzo, Cena, Comer Solo, Turistas, Debito

Recomendación #206746:


Nombre: Un Mundo De Sabor

Promedio: 4.8

Valoraciones: 67


Categorías: Categoría Desconocida, Categoría Desconocida

Atributos: Takeout, Delivery, Estacionamiento Discapacitados, Cena, Comer Solo, Debito, NFC, Credito



Extra - Análisis de Sentimientos

Cantidad de gmap_id únicos por Estado (Positivos y Negativos)



Continuidad

Propusimos dos alternativas altamente fiables, lo que le brinda al cliente la posibilidad de elegir sobre sus preferencias la alternativa que mejor se adapte a sus necesidades.

Destacamos lograr la:

- Implementación 100% en la nube.
- Despliegue en Servidor Local Privado.



Próximos Pasos



Análisis de Sentimientos

Obtener el análisis de la industria en general.



Dashboard


Generar un tablero de mando con los KPIs fijados en el primer sprint



Algoritmo de Recomendaciones

Desarrollar el algoritmo para que el cliente se retroalimente de las críticas de los usuarios.





▶▶▶▶ 100%



Gracias por su Atención



Nos vemos en la última Sprint

